ANTLab 考核·整合实验报告

方向：Agent（文档阅读与信息核验）丨进阶题 B（系统失效诊断）丨2026 年 10 月 16 日

一、完成概览

表 1 完成概览

部分	完成情况	最值得核验的结果与路径
基础题（必做）	D01–D04 通过；40 次主请求（T01–T08 × R0/R1/R2/K）完成；改进 v6 使 R0 正确率由 4/8 提升至 7/8	results/results.csv（40 次记录）；R0 改进逐题结果见二、表 2
进阶题 B（选做）	主故障 R02 缓存污染修复完成；回归与三类等价变体全部通过；R03/R04 与 E1/E2 登记未解决	进阶 /challenge_b/runs/{baseline,fixed,variants}.json；compare.html
提交物	代码、运行记录、对比页面、本报告已推送；AI 声明见四	README.md 与收集表 commit SHA

完成概览小结：基础题按“读文档—找证据—给答案—引文支持”管线完成全部八题主请求，R0 条件经多轮改进由 4/8 提升到 7/8，其中 T08 经多次采样验证为采样方差而非系统性错误；进阶题 B 完成源码审查、故障归因与最小修复全流程，主故障修复后原本正常用例无回归。

二、基础题（文档阅读与信息核验）

2.1 任务机制

样机接收“问题＋资料段落”，通过模型检索证据、给出答案并附引用；判分按“答案正确”与“引用支持”分开核查。本人实现 student.py 的 prepare_messages （system 角色约束＋防编造；user 全篇阅读＋跨段证据＋证据不足规则＋引用格式）与 improve（针对失败案例定向改进选段）。

2.2 R0 条件逐题结果（改进 v6，最新一次 paid 运行）

表 2 基础题 R0 改进结果（来源：基础/results/results.csv）

题目	答案	引用（citations）
T01	S24	P555495
T02	76%	P169676,P552476
T03	2.6	P362285,P385105
T04	流程乙	P758661,P660995
T05	证据不足	（空）
T06	25%	P873502,P721388
T07	丙	P850395,P313278
T08	K17	P183430

改进历程：v2（引用完整性）→ v4（证据不足判定）→ v6（跨段证据与格式收敛），R0 正确率 4/8 → 7/8；T08 经 5 次采样证明为采样方差（非稳定错误）。R1/R2/K 条件均按题包要求完成主请求，原始输出全部保留于 runs/ 与 results/results.csv。

三、进阶题 B（源码审查、故障归因与修复）

3.1 结论摘要

样机为文档查证工具：输入“问题＋文档＋版本”后从 6 条证据（b01–b06，alpha/beta 两文档、v1/v2 两快照）中检索、作答并标注支持状态。对照 spec 六条契约，基线 7 个用例（R01–R07）暴露 3 个症状和 1 个边界问题。主故障选定 R02 缓存污染：请求 v2 快照却返回 v1 旧结论（30 秒而非 12 秒）。根因为缓存键仅含 query 文本；修复为将缓存键扩展为（query, doc_ids, snapshot, k）四元组。修复后 R02 正确返回 v2/b02/12 秒，回归与三类等价变体全部通过；R03、R04 两个症状与 E1、E2 两个边界如实登记未解决。

3.2 基线症状识别

表 3 基线症状一览

症状	Case	基线现象	违反 spec
换了资料版本却显示旧结论	R02	请求 v2 快照，返回 v1 的 b01 与“30 秒”，cache_hit=true	第 5 条
指定了文档却漏掉证据	R03	doc_ids=beta 且范围内存在可匹配 b03，evidence 却为空	第 2 条
引文可点击但“已验证”不可信	R04	答案称“保证释放 GPU”，证据明确“未测量服务端”，仍标 supported	第 4 条
未知文档未明确拒绝	R07	doc_ids=missing 返回 status=ok 而非 invalid_scope	第 1 条

3.3 根因定位（先预测再检查）

表 4 候选原因与可观察预测

候选原因	可观察预测	基线证据	结论
嫌疑 A：缓存键仅含 query 文本	R02 输出 cache_hit=true，证据为 v1 的 b01	R02：cache_hit=true，b01，30 秒	A 应验
嫌疑 B：代码未区分快照版本	R02 输出 cache_hit=false，证据仍为 v1 条目	R02 的 cache_hit=true，与预测不符	B 排除

源码确认：challenge.py 第 12 行 key = query.strip().lower()，缓存键仅取问题文本，R02 与 R01 文本相同故命中 v1 缓存。

3.4 修复结果与回归、变体

表 5 修复前后对照（同输入、同重放）

Case	修复前	修复后	差异
R01	b01；30 秒	b01；30 秒	不变
R02	b01；30 秒（cache_hit=true）	b02；12 秒（cache_hit=false）	修复生效
R03	（空）；5 秒	（空）；5 秒	不变
R04	b04；保证释放 GPU	b04；同左	不变
R05	b05；文档编号为 beta	b05；同左	不变
R06	b06；未测试多 worker	b06；同左	不变
R07	（空）；这个文档存在	（空）；同左	不变

表 6 等价变体结果（版本切换/标识重映射/词序）

变体	请求要点	输出
V1a_alpha_v2	alpha；v2；k=2	b02；12 秒
V1b_alpha_v2_repeat	相同请求再问一次	b02；12 秒（合法复用缓存）
V1c_alpha_v1_after_v2	v2 之后立即问 v1	b01；30 秒（无跨版本污染）
V2a_docA_v1	docA；v1；k=2	b01；30 秒
V2b_docA_v2	docA；v2；k=2	b02；12 秒
V3a_permuted_order	threshold timeout request	b02；12 秒

3.5 登记症状与未解决边界

表 7 登记症状（修一登记二）

症状	代码依据	处理
R03 漏证据	challenge.py 第 18–19 行：先全局取前 k 名再按范围过滤	登记，不在本次修复范围
R04 语义支持误判	challenge.py 第 25 行：引用 ID 在证据中即标 supported	登记，需语义检查或降级

自构造两个未解决边界：E1（合法文档＋未知快照 v9）、E2（未知文档 missing），当前均返回 status=ok 而未返回 spec 第 1 条要求的 invalid_scope；该边界属“未知组合校验”独立缺陷，与缓存污染无关，最小修复刻意不越权处理。

四、决策记录与 AI 使用申报

表 8 三项关键决策

决策	本人判断	替代方案	最终决定
选方向 B	离线零 API 费用、工作量可控、与基础题基线—修复结构同构	A 需 API 密钥与 token；C 需论文精读	B
主故障选 R02	契约最硬（spec 第 5 条）、可复现、修复最小	R04 语义误判（影响面大）	R02
修复方案	保留等价输入缓存复用（spec 允许）、改动最小	关闭缓存；命中后回退重算	四元组缓存键

本任务以本人判断为主线，AI 提供辅助支撑。

本人参与与判断：选定方向 B；从基线症状中选定主故障 R02；审阅并确认两个候选原因与可观察预测；审阅修复方案后确认执行；逐项核验回归、变体与边界结果。

AI 协助：协助识别症状、起草候选原因与预测、编写修复引擎与变体脚本、生成对比页面与报告。

合规保证：所有预测先于干预记录；基线、修复与变体运行记录全部保留且未覆盖；AI 的输入仅限任务公开材料与运行产物，未读取参考答案文件，未修改 data.json 与任何 draft；人工评测标签未伪装为系统输出，judgment_source 均为 rule。

五、复现与证据索引

基础题（在 基础 目录）：python starter/runner.py --case D01 --condition E --paid --config config.local.json（换题改 --case）；结果导出 python starter/export_runs.py runs results.csv。

进阶 B（在 进阶/challenge_b 目录）：python run_cases.py --output runs/baseline.json（基线）；python run_cases.py --engine my_engine:Engine --output runs/fixed.json（修复后）；python run_variants.py（变体与边界）；python check_fix.py（对照）；浏览器打开 compare.html（对比页面）。

表 9 证据索引

证据	位置
基础题 40 次运行原始记录	基础/results/results.csv；基础/runs/
基础题逐题清单与资料	基础/（题目 01–08）
进阶 B 基线/修复/变体运行记录	进阶/challenge_b/runs/{baseline,fixed,variants}.json
进阶 B 修复引擎与脚本	进阶/challenge_b/my_engine.py、run_variants.py、check_fix.py
修复前后对比页面	进阶/challenge_b/compare.html